

Predicción de la Renovación de la Matrícula Mercantil mediante Regresión Logística

Kevin Esteban Díaz Pinilla

Especialización analítica y ciencia de datos

Universidad de Cundinamarca

Machine Learning

Mónica María Fonseca Vigoya

02 de octubre de 2026

Introducción

La matrícula mercantil es el registro que permite a una persona natural o jurídica ejercer el comercio en Colombia, y debe renovarse cada año dentro de los tres primeros meses, según el artículo 33 del Código de Comercio. Cuando una empresa deja de renovar durante cinco años, el artículo 31 de la Ley 1727 de 2014 prevé la disolución y liquidación de las sociedades y la cancelación de la matrícula de las personas naturales y los establecimientos de comercio. La renovación es, por tanto, una señal observable de que una empresa sigue activa.

Para las cámaras de comercio por lo tanto resulta útil anticipar qué empresas renovarán, porque permite dirigir recordatorios, planear los ingresos por renovaciones y priorizar la depuración del registro. Este trabajo aborda ese problema como una clasificación binaria: a partir de características básicas de cada empresa se estima la probabilidad de que renueve (1) o no (0) su matrícula.

El objetivo general es estimar la probabilidad de renovación de la matrícula mercantil mediante un modelo de regresión logística. Los objetivos específicos son:

- Preparar y depurar la base de datos
- Explorar la relación entre las variables explicativas y la renovación,
- Entrenar el modelo y
- Evaluarlo con accuracy, matriz de confusión, precisión, recall y F1.

Método

Datos

Se utilizó una base del registro mercantil con 500.000 registros y 12 columnas encontrada en la base de datos de Kaggle, que describen la cámara de comercio, el tipo de sociedad, la organización jurídica, la actividad económica, la antigüedad de la empresa y su último año

renovado, entre otras características. Sin embargo entre todas estas columnas, la variable de interés que se escogió es la de , renovó, vale 1 si la empresa renovó su matrícula y 0 si no lo hizo.

Depuración y Control de Fuga de Información

En la limpieza de la base de datos se encontraron inconsistencias, por lo tanto, se eliminaron 36.938 registros con año de última renovación igual a 0, un valor que no corresponde a un año real (todos tenían renovó igual a 0), y 2 registros con antigüedad superior a 100 años, un error que se puede considerar atípico. Por otra parte, se encontraron 102 valores vacíos de organización jurídica que se rotularon como “SIN INFORMACION”. Después de la depuración descrita, la base final quedó con 463.060 registros.


Un control central fue descartar las variables último año renovado y años sin renovar ya que se consideraron obvias e innecesarias por estas razones:

La variable renovó vale 1 exactamente cuando el último año renovado es 2024 o 2025 (Figura 1), de modo que incluirla entrega la respuesta al modelo, situación conocida como fuga de información.

Años sin renovar se excluyó por la misma razón, pues equivale a 2025 menos el último año renovado.

Figura 1

Proporción de Empresas que Renovaron según su Último Año Renovado



Nota. Las empresas con último año renovado igual o anterior a 2023 figuran todas como no renovadas, y las de 2024 y 2025 como renovadas (n = 463.060). Elaboración propia.

Variables

Las variables explicativas finales fueron cuatro: tipo de persona (recodificada como 1 = jurídica y 0 = natural), antigüedad de la empresa en años, cámara de comercio y organización jurídica. Como la regresión logística solo procesa números, las dos últimas, de tipo texto, se transformaron en variables indicadoras (0/1) y se omitió una categoría de referencia por variable, lo que produjo como resultado 93 columnas.

Como se explico al principio, la variable Y que a su vez es el objetivo general, corresponde a la columna renovó.

Modelo

El ejercicio es de clasificación porque la variable de respuesta es una categoría y no un valor continuo como lo es en una regresión lineal. La regresión logística estima la probabilidad de la clase 1 aplicando la función sigmoide a una combinación lineal de las variables; sus coeficientes, al exponenciarse, se interpretan como razones de odds. El método *fit()* ajusta esos

coeficientes con los datos de entrenamiento, *predict()* entrega la clase estimada con un umbral de 0,5 y *predict_proba()* entrega la probabilidad de renovar.

Procedimiento

Los datos se dividieron de forma aleatoria y estratificada en 80 % para entrenamiento (370.448 registros) y 20 % para prueba (92.612), con semilla 42, de modo que ambos conjuntos conservaron la misma proporción de renovaciones (48,7 %). El modelo se entrenó con la implementación de scikit-learn, con un máximo de 2.000 iteraciones. Para corroborar esta información el procesamiento y las gráficas se realizaron en Python con pandas y seaborn, en Google Colab.

Métricas de Evaluación

El desempeño se midió únicamente en el conjunto de prueba. Se calcularon el accuracy, proporción de aciertos; la precisión, proporción de predicciones “renovó” que fueron correctas; el recall, proporción de renovaciones reales detectadas; el F1, media armónica de las dos anteriores; y el AUC-ROC, que indica qué tan bien el modelo ordena las empresas según su probabilidad, por último se elaboró la matriz de confusión, que cruza la clase real con la predicha.

Resultados


Descripción de los Datos

La Figura 2 muestra la relación de dos variables explicativas con la renovación donde se determina la proporción de empresas que han renovado junto con su cantidad de años de antigüedad. Esta última, es la más marcada: renovó el 99 % de las empresas con 0 años y el 97 % de las de 1 año, frente a 80 % con 2 años, 51 % con 5, 36 % con 10 y 30 % con 20. La gráfica de la derecha pretende representar el top 8 de cámaras de comercio que reciben mayores

registros mercantiles de sus empresas. Por cámara de comercio, la tasa va de 71 % en Bucaramanga y 70 % en Villavicencio a 42 % en Bogotá y 39 % en Cartagena.

Figura 2

Tasa de Renovación según la Antigüedad y la Cámara de Comercio



Nota. Se muestran ocho de las diez cámaras con más registros. Elaboración propia a partir de la base depurada (n = 463.060).

Desempeño del Modelo

La Tabla 1 representa el resultado de las evaluaciones, el modelo final subió a 0,702 de accuracy y a 0,738 de AUC.

Tabla 1

Desempeño de los Modelos según las Variables Incluidas

Modelo	Accuracy	Precisión	Recall	F1	AUC
4 variables	0,702	0,701	0,678	0,689	0,738

Nota. AUC = área bajo la curva ROC.

El modelo final tuvo un desempeño parejo en ambas clases (Tabla 2): precisión de 0,70 en cada una, recall de 0,73 para las empresas que no renovaron y de 0,68 para las que sí renovaron, y F1 de 0,71 y 0,69.


Tabla 2*Métricas del Modelo Final por Clase*

Clase	Precisión	Recall	F1	n
No renovó	0,70	0,73	0,71	47.511
Renovó	0,70	0,68	0,69	45.101
Accuracy			0,70	92.612
Promedio macro	0,70	0,70	0,70	92.612

Nota. Resultados del informe de clasificación sobre el conjunto de prueba. n = número de empresas reales de cada clase.

La matriz de confusión (Figura 3) muestra 34.460 verdaderos negativos y 30.563 verdaderos positivos, frente a 13.051 falsos positivos (se predijo renovación y no ocurrió) y 14.538 falsos negativos (se predijo no renovación y la empresa renovó). Los errores se reparten de forma pareja, lo que indica que el modelo no favorece a ninguna clase.

Esta misma (Figura 3) representa los porcentajes una vez divididos frente a la población total, Realmente no renovó $34.460 / 47.511 = 72,5 \%$ (verdaderos negativos), $13.051 / 47.511 = 27,5 \%$ (falsos positivos), Realmente renovó $14.538 / 45.101 = 32,2 \%$ (falsos negativos), $30.563 / 45.101 = 67,8 \%$ (verdaderos positivos)

Figura 3*Matriz de Confusión del Modelo Final en el Conjunto de Prueba*

Nota. Entre paréntesis, el porcentaje respecto del total de cada fila (clase real). n = 92.612.

Interpretación de los Coeficientes

Las razones de odds del modelo final (Tabla 3) indican que, manteniendo lo demás constante, cada año adicional de antigüedad multiplica por 0,924 las probabilidades de renovar, es decir. Frente a su categoría de referencia, cámaras como Cartagena (0,171) y Bogotá (0,244) tienen menores probabilidades de renovar, y las sociedades anónimas (1,801) y en comandita simple (2,576) tienen mayores.

Tabla 3

Razones de Odds Seleccionadas del Modelo Final

Variable	Razón de odds	Efecto sobre la renovación
Antigüedad (por año adicional)	0,924	Reduce
Cámara: Cartagena	0,171	Reduce
Cámara: Bogotá	0,244	Reduce
Cámara: Barranquilla	0,358	Reduce
Cámara: Montería	1,498	Aumenta
Cámara: Sincelejo	1,823	Aumenta
Organización: persona natural	0,450	Reduce
Organización: S.A.S.	1,528	Aumenta
Organización: sociedad anónima	1,801	Aumenta
Organización: sociedad en comandita simple	2,576	Aumenta

Nota. Razón de odds = e elevado al coeficiente. Cada categoría se compara con la categoría de referencia de su variable (la primera en orden alfabético, omitida al crear las variables indicadoras). Se muestran solo categorías con al menos 1.000 registros. Los resultados se entienden de esta manera: Mayor a 1: aumenta las probabilidades de renovar. Menor a 1: las reduce. Igual a 1: no influye.

Efecto del Umbral de Decisión

Como *predict_proba()* entrega probabilidades, el umbral de decisión puede modificarse (Tabla 4). Subirlo aumenta la precisión a costa del recall: con 0,60 la precisión es 0,761, pero el recall cae a 0,418. El mejor F1 aparece con un umbral de 0,45 (0,702, frente a 0,689 con 0,50).

Tabla 4*Precisión, Recall y F1 según el Umbral de Decisión*

Umbral	Precisión	Recall	F1
0,35	0,569	0,870	0,688
0,40	0,606	0,823	0,698
0,45	0,647	0,767	0,702
0,50	0,701	0,678	0,689
0,55	0,743	0,571	0,646
0,60	0,761	0,418	0,539

Nota. Conjunto de prueba. El umbral por defecto de predict() es 0,50. En negrita, el umbral con mayor F1.

Discusión

El modelo final clasifica correctamente a 7 de cada 10 empresas, con un desempeño equilibrado entre clases.

Es probable que el techo de alrededor de 70 % se deba a factores que la base no contiene, como la situación financiera o el cierre efectivo del negocio lo que significa una limitación.

Se identifico también que influye la forma de la relación con la antigüedad: la tasa de renovación cae con los años, pero vuelve a subir en las empresas más antiguas (51 % entre quienes tienen 30 años o más), y la regresión logística supone una relación lineal.

Conclusiones

La regresión logística permitió estimar la probabilidad de renovación de la matrícula mercantil con un accuracy de 0,702, un F1 de 0,689 y un AUC de 0,738, sin sesgo marcado hacia ninguna clase. La antigüedad y la cámara de comercio fueron las variables más informativas, y excluir el último año renovado fue indispensable para evitar la fuga de información.

LINK DEL REPOSITORIO: <https://github.com/kevindiaz0802/Regresi-n-logistica.git>